

# CLASIFICADOR DE IMÁGENES DE ARQUITECTURA

PROYECTO DE MACHINE  
LEARNING

Juan Bayón

# ÍNDICE

PLANTEAMIENTO

ESTILOS

ANÁLISIS Y TRATAMIENTO DE LOS DATOS

MODELO BASE

ENTRENAMIENTO MODELOS SKLEARN

REDES NEURONALES

APRENDIZAJE NO SUPERVISADO

REDES NEURONALES PREENTRENADAS

RESUMEN MODELOS

CONCLUSIONES

# PLANTEAMIENTO

# PLANTEAMIENTO

Se busca desarrollar un clasificador de imágenes de estilos arquitectónicos representativos del siglo XX

Los estilos elegidos son:

- Art Nouveau
- Art Deco
- Estilo internacional
- Posmodernismo
- Deconstructivismo

# DATOS

Para el proyecto se han usado dos dataset procedentes de Kaagle:

- Architectural styles, con dos dataset con imágenes etiquetadas.
- g-images con imágenes etiquetadas provinientes de google de los mismos estilos.

# ESTILOS



# ART NOUVEAU (MODERNISMO)

- Empieza a finales del siglo XIX hasta el siglo XX. Del 1890 al 1920
- Inspiración en la naturaleza incorporando los avances en materiales como el acero o el cristal
- Se propone democratizar la belleza y que hasta los objetos más cotidianos tuviese valor estético
- Uso de líneas curvas y sinuosas, con composiciones muchas veces asimétricas
- Decoración y arquitectura se unen con formas orgánicas




CASA BATLLÓ. GAUDÍ



# ART DECO

- Entre 1920 y 1940. Presente en todas las artes, basado en la artes decorativas.
- Líneas geométricas contundentes. Bordes redondeados. Composiciones simétricas.
- Gran presencia de cubos y rascacielos con líneas sólidas.
- Materiales como el aluminio, acero inoxidable o el cristal.
- Especial cuidado en los ornamentos, con el uso de patrones y tipografías visibles.

EDIFICIO CHRYSLER. WILLIAM VAN ALLEN





# ESTILO INTERNACIONAL (RACIONALISMO)

- Entre 1925 y 1965. Movimiento mayoritario en todo el mundo
- Grandes maestros de la arquitectura como Mies van der Rohe o Le Corbusier.
- Basada en la razón. Funcionalismo. Líneas sencillas Formas geométricas simples: cubo, paralelepípedo, cilindro, esfera
- Materiales industriales: acero, hormigón, vidrio
- Mejorar el uso de los espacios sin nada superfluo.



CASA FARNSWORTH. MIES VAN DER ROHE



# POSMODERNISMO

- A partir de los años 50, especialmente en los 70, resupuesta al estilo internacional tan sobrio.
- Volver al ingenio, al ornamento y a la referencia.
- Se usan ornamentos en fachada, con ángulos no ortogonales.
- Enfatizar los volúmenes y llamar la atención.
- Los estilos se fusionan entre ellos. También llamado 'neoecléctico' que mezcla diferentes estéticas.



EDIFICIO M2. KENZO ZUMA

# DECONSTRUCTIVISMO

- Finales de la década de los 80 y presente hasta hoy
- Fragmenta los volúmenes. Formas no rectilíneas ni planas. Apariencia con un caos controlado.
- Múltiples capas. Intención de experimentación formal creando desequilibrios geométricos.
- Un ejemplo muy reconocible en España es el Guggenheim de Bilbao.



MUSEO GUGGENHEIM. FRANK GEHRY

# ANÁLISIS Y TRATAMIENTO DE LOS DATOS



Art Nouveau



Posmoderno



Deconstructivismo




Internacional



Art Deco



Posmoderno



Las fotografías tienen diferentes tamaños, la mayoría en color.

Se estandariza su tamaño a 250x250 en color.


Hay varias imágenes de los edificios más representativos, sacadas desde diferentes ángulos.

No se aprecia ningún elemento extraño.  
Dataset limpio y listo para ser utilizado.


# ANÁLISIS DE LOS DATOS



Postmoderno



Internacional



Internacional



Art Deco



Art Deco



Art Deco



Se aumentan los datos con de manera aleatoria alternando al azar entre los siguientes parámetros:

**ROTACIÓN.** 30 grados

**ZOOM.** 20% para alejar o acercar

**RANGO ANCHURA.** 10% de variación

**RANGO ALTURA.** 10% de variación.

**GIRO HORIZONTAL.**

**ÁNGULO CORTE.** 0,15 Ángulo de corte.

Se rellenan las zonas que se crean nuevas con el criterio de píxeles más cercanos.

**DATA AUGMENTATION**

# MODELO BASE

Se separan los conjunto de entrenamiento y de test

Se cargan los datos con sus etiquetas desde las carpetas de proyecto

Se elige el modelo base: Regresión Logística

Se entrena con los siguientes parámetros:

- 10 iteraciones
- sin penalizador
- solver lbfgs

**SE OBTIENE UN 35,25 % DE ACIERTO EN EL TEST**

MATRIZ CONFUSION TEST

`[[40 26 8 10 17]`

`[24 52 10 8 7]`

`[25 22 18 24 12]`

`[15 14 9 37 26]`

`[17 21 12 20 31]]`

**MODELO BASE: REGRESIÓN LOGÍSTICA**

Se coge un tercio de los datos para probar los modelos

Se vuelve a comprobar el resultado con el modelo base y los datos de muestra.

Dado el parecido en el resultado se entrena con la muestra y los mejores se entrenarán con todos los datos.

**SE OBTIENE UN 31,88 % DE ACIERTO EN EL TEST**

MATRIZ CONFUSION TEST

`[[32 25 13 18 13]`

`[30 41 7 12 11]`

`[16 14 14 34 23]`

`[15 6 10 40 30]`

`[14 12 9 32 34]]`

CONJUNTO DE MUESTRA

# ENTRENAMIENTO MODELOS SKLEARN



## SEMILLAS

SEMILLAS: 54185, 19294,  
19966, 74724, 34541

## ITER MAX

ITER\_MAX: 10, 100, 900

## GRID SEARCH

PENALIZADOR: l1, l2

C : 0.01, 0.1 , 0.5, 1

No se consiguen mejoras  
con el cambio de semillas.

**ACIERTO: 31,88%**

100 funcionan igual que 900.  
Mejora un 3% el resultado

**ACIERTO: 34, 45%**

Se mejora el modelo base  
en un 5% con C = 0.1 y l2

**ACIERTO: 37, 03%**

# REGRESIÓN LOGÍSTICA

## KNN BASE

Se crea un modelo con los parámetros por defecto con  $k=5$ .

No mejora el modelo base

**ACIERTO: 29,11%**

## GRID SEARCH

VECINOS : 3, 5, 11, 19

PESOS: uniform, distance

MÉTRICA: euclidean, manhattan

Se mejora el modelo base  
en un 9% con  $C = 0.1$  y  $l2$

**ACIERTO: 40,39%**

## MODELO KNN

## SVC BASE

## SEMILLAS

## GRID SEARCH

SEMILLAS: 39095, 85951,

41047, 85884, 77579

KERNEL: linear, rbf, sigmoid

GAMMA: scale, auto

C: 0.001, 1, 10

No se consiguen mejoras.

Parámetros por defecto:  $C = 1$ ,  
kernel = rbf, gamma = scale

**ACIERTO: 27,52%**

No se consiguen mejoras  
con el cambio de semillas.

**ACIERTO: 27,52%**

Se mejora en un 12% el  
modelo base con  $C = 10$ ,  
gamma = scale, kernel = rbf

**ACIERTO: 43,36%**

# SVC

## FOREST BASE

## GRID SEARCH

## WARM START

N\_ESTIMATORS: 1, 100, 1000

N\_ESTIMATORS: 1000

MAX\_FEATURES: 1, 2, 3

MAX\_FEATURES: 3

N\_SPLITS = 10

No se consiguen mejoras.  
Parámetros por defecto.

Se mejora el modelo base  
en un 11% con n\_estimators =  
1000 y max\_features = 3

Con n\_estimators = 1000,  
max\_features = 3 y 10  
iteraciones con cross validation

**ACIERTO: 28,91%**

**ACIERTO: 42,37%**

**ACIERTO: 43,56%**

## RANDOM FOREST

## MEJOR MODELO

- EL MEJOR MODELO PROBADO ES EL DE RANDOM FOREST CON ENTRENAMIENTO EN CALIENTE
- SE PRUEBA EL MEJOR MODELO CON TODOS LOS DATOS
- **SE OBTIENE UN 61% DE ACIERTO**
- PARÁMETROS: N\_ESTIMATORS = 1000, MAX\_FEATURES = 3, N\_SPLITS = 10

## RESUMEN SKLEARN



# REDES NEURONALES

## CAPAS

Convolucion2D: 32 neuronas. Padding same. Activación Relu

MaxPooling2D

Convolucion2D: 32 neuronas. Padding same. Activación Relu

MaxPooling2D

Convolucion2D: 64 neuronas. Padding same. Activación Relu

MaxPooling2D

Dropout: 40%

Flatten

Dense: 128 Neuronas. Activación Relu

Dense: 5 Neuronas. Activación Softmax

## COMPILACIÓN:

Optimizador: Adam

Loss : Categorical Crossentropy

Metrica: Accuracy

**ACIERTO: 58,29%**

# RED NEURONAL

Se prueban diferentes parámetros con la misma red, y otras redes neuronales:


- Función de activación: tangente hiperbólica, sigmoide
- Inicializador kernel: uniform y he\_uniform
- Optimizador: sgd
- Épocas: 10, 15, 100
- Configuraciones de capas diferentes

**NO SE CONSIGUEN MEJORAS EN EL PORCENTAJE DE ACIERTO**

**PRUEBAS RED NEURONAL**

# APRENDIZAJE NO SUPERVISADO

Art Deco



Art Deco



Art Deco



Art Deco



Art Deco



Art Deco



Se aplica aprendizaje no supervisado a las imágenes.

Kmeans con clusters = 25. Reducción a 25 colores.

**Dataset con la red neuronal: acierto de un 68, 55%**

**Dataset con Random Forest: acierto de un 73,71%**

**MEJORAN MUCHO LOS RESULTADOS CON LOS  
NUEVOS DATOS**

**KMEANS**



# RED NEURONAL PREENTRENADA

## CAPAS

Capas preconfiguradas VGG16

Dense: 512 Neuronas. Activación Relu

Dropout: 50%

Dense: 5 Neuronas. Activación Softmax

## COMPILACIÓN:

Optimizador: Adam

Loss : Categorical Crossentropy

Metrica: Accuracy

**ACIERTO: 85,89%**

**RED NEURONAL VGG16**

## CAPAS

Capas preconfiguradas EfficientNetB2

Dense: 512 Neuronas. Activación Relu

Dropout: 50%

Dense: 5 Neuronas. Activación Softmax

## COMPILACIÓN:

Optimizador: Adam

Loss : Categorical Crossentropy


Metrica: Accuracy

**ACIERTO: 89,74%**

**RED NEURONAL EFFICIENTNETB2**

# RESUMEN MODELOS

## ACIERTO DE LOS MODELOS



## TOP 10 MODELOS

1. EFFICIENTNETB2. DATA KMEANS
2. VGG16. DATA KMEANS
3. RANDOM FOREST WARM START. DATA KMEANS
4. RED NEURONAL CON DATA KMEANS
5. RANDOM FOREST WS. DATA ORIGINAL COMPLETO
6. RED NEURONAL DATA KMEANS AUMENTADOS
7. RED NEURONAL DATA ORIGINAL 1
8. RED NEURONAL DATA ORIGINAL 2
9. RED NEURONAL DATA ORIGINAL 3
10. RANDOM FOREST WS. DATA ORIGINAL MUESTRA

# CONCLUSIONES



# CONCLUSIONES

- Los algoritmos de **aprendizaje no supervisado** para tratar las imágenes previamente **mejoraron mucho** los resultados y permitieron llegar casi al 90%
- El modelo de **Random Forest consiguió muy buen resultado** y tiene muy **buen rendimiento** a la hora de calcular los modelos.
- Las **redes neuronales preentrenadas mejoraron el aprendizaje del resto de modelos**. Se probaron otras que no daban buenos resultados, por lo que fue necesario buscar las que se adaptan mejor a los datos.

**MUCHAS  
GRACIAS**

**github\_linkedin\_correo:  
Juan\_Bayon  
Juan Bayon Fernandez  
juanbayonfernandez@gmail.com**